Pembersihan dan Validasi Data

Bahan bacaan ringkas untuk praktik kelompok

Data mentah sering berisi nilai kosong, catatan ganda, penulisan yang tidak seragam, atau angka yang tidak masuk akal. Jika masalah tersebut dibiarkan, hasil analisis dapat menyesatkan. Karena itu, manusia perlu memeriksa data, menetapkan aturan, memperbaiki masalah yang dapat dibuktikan, lalu mencatat setiap perubahan.

Pada kegiatan ini, kamu akan memperlakukan data sebagai bukti. Setiap perubahan harus memiliki alasan dan dapat ditelusuri kembali ke data sumber. Tujuannya bukan membuat tabel terlihat rapi, melainkan menghasilkan data yang layak digunakan.

Tujuan Pembelajaran

- Mengidentifikasi masalah kualitas pada sebuah dataset sederhana.
- Menerapkan aturan pembersihan dan validasi data secara mandiri atau berkelompok.
- Menjelaskan alasan perubahan melalui catatan perubahan yang jelas.

Tiga Ciri Hasil yang Baik

Ciri	Makna	Pertanyaan pemeriksa
Bersih	Format seragam, tidak ada duplikasi yang tidak perlu, dan data siap diolah.	Apakah tabel konsisten dan mudah diproses?
Benar	Nilai sesuai fakta, aturan, atau sumber asli yang dapat diperiksa.	Apakah nilai ini dapat dibuktikan?
Terpercaya	Asal data, cara pengumpulan, dan perubahan dapat ditelusuri.	Siapa sumbernya dan apa yang sudah diubah?

Enam Cara Menilai Kualitas Data

Dimensi	Makna	Dimensi	Makna
Kelengkapan	Nilai penting tersedia.	**Keunikan**	Satu entitas tidak tercatat ganda.
Konsistensi	Nilai dan format tidak saling bertentangan.	**Kebaruan**	Data sesuai periode penggunaan.
Validitas	Nilai mengikuti format dan rentang yang ditetapkan.	**Akurasi**	Nilai sesuai keadaan sebenarnya.

Masalah yang Sering Ditemukan

Masalah	Contoh	Tindakan awal
Data kosong	Durasi belajar tidak diisi	Tandai dan konfirmasi. Jangan langsung mengisi nol.
Data ganda	Baris S03 tercatat dua kali	Bandingkan seluruh kolom dan sumber asli.
Format berbeda	09/09/2026 dan 2026-09-09	Tetapkan satu format yang disepakati.
Kategori tidak seragam	YouTube, youtube, YT	Gunakan daftar kategori atau kode yang jelas.
Nilai tidak valid	Durasi belajar 25 jam per hari	Periksa rentang dan konfirmasi kepada sumber.
Kesalahan ketik	Matematiak	Perbaiki hanya jika maksudnya dapat dibuktikan.
Data tidak relevan	Warna favorit untuk analisis durasi belajar	Hapus dari tabel kerja, tetapi simpan data asli.

Proses Komputasi yang Dilakukan Manusia

1. Tetapkan tujuan. Tentukan informasi yang ingin diperoleh dan kolom yang dibutuhkan.

2. Periksa data mentah. Baca tabel tanpa mengubahnya. Tandai pola dan nilai yang mencurigakan.

3. Identifikasi masalah. Kelompokkan masalah sebagai data kosong, ganda, tidak konsisten, atau tidak valid.

4. Buat aturan pembersihan. Contoh: semua durasi disimpan dalam menit dan tanggal memakai format DD-MM-YYYY.

5. Terapkan dan validasi. Ubah salinan data, lalu bandingkan hasilnya dengan aturan dan sumber asli.

6. Catat perubahan. Tuliskan sel yang diubah, nilai awal, nilai akhir, alasan, dan cara verifikasinya.

Aturan Keputusan Sebelum Mengubah Data

- Perbaiki jika ada bukti yang cukup, misalnya salah ketik yang dapat dibandingkan dengan formulir asli.
- Seragamkan format dengan aturan yang disepakati bersama.
- Tandai atau konfirmasi jika nilai masih meragukan. Jangan menebak.
- Hapus hanya setelah memastikan data memang ganda, tidak relevan, atau tidak dapat digunakan.
- Simpan data mentah terpisah agar setiap perubahan dapat dilacak.

Contoh Pemeriksaan Dataset

Dataset berikut bersifat fiktif dan tidak menggunakan data pribadi. Tujuan pengolahan adalah mengetahui kebiasaan belajar siswa. Periksa setiap baris sebelum memutuskan perubahan.

Kode	Tanggal	Durasi	Media	Temuan awal
S01	09/09/2026	2 jam	YouTube	Satuan durasi dan format tanggal belum baku
S02	2026-09-09	120 menit	youtube	Kategori dan format tanggal berbeda
S03	09-09-26	(kosong)	Buku	Durasi kosong
S03	09-09-26	(kosong)	Buku	Kemungkinan baris ganda
S04	09/09/2026	25 jam	YT	Nilai durasi tidak masuk akal

Contoh Catatan Perubahan

Lokasi	Nilai awal	Tindakan	Hasil	Alasan atau bukti
S01 durasi	2 jam	Konversi satuan	120 menit	Aturan kelompok memakai menit
S02 media	youtube	Seragamkan kapital	YouTube	Daftar kategori
S03 baris 2	Sama dengan baris 1	Hapus setelah verifikasi	1 baris S03	Baris identik pada sumber
S04 durasi	25 jam	Tandai untuk konfirmasi	Belum diubah	Melebihi batas 24 jam

Checklist Hasil Kelompok

☐ Data mentah tetap tersimpan dan tidak ditimpa.

☐ Kelompok memiliki aturan pembersihan sebelum mengubah data.

☐ Setiap perubahan memiliki alasan atau bukti.

☐ Nilai meragukan ditandai untuk dikonfirmasi, bukan ditebak.

☐ Dataset hasil dan catatan perubahan dapat diperiksa kelompok lain.

Pertanyaan Pemahaman

- Mengapa data yang rapi belum tentu benar?
- Kapan data kosong boleh diisi, dan kapan sebaiknya dibiarkan kosong?
- Mengapa nilai pencilan tidak selalu boleh dihapus?
- Bukti apa yang membuat sebuah perubahan dapat dipercaya?

Sumber

- Modul Analisis Data, bagian F.3 Validitas Data dan F.4 Siklus Hidup Data.
- Kementerian Pendidikan Dasar dan Menengah. Capaian Pembelajaran Informatika Fase E (kurikulum.kemendikdasmen.go.id).
- UK Government. The Government Data Quality Framework (gov.uk).